Recuperação de informação

Coleta e busca de entidades estruturadas em um domínio

Equipe & Tarefas

Isaac Douglas Webcrawler

Wellington Felix Classificação e extração

Domínio: Smartphones

Sites:

- 1. Banggood
- 2. Apple
- 3. Samsung
- 4. Asus
- 5. LG
- 6. Xiaomi
- 7. Motorola
- 8. Sony
- 9. Blu
- 10. HTC

















SONY htc

Task 1

Localização de páginas relevantes

Resultados Busca em largura

Files = 9.195

	Naïve Bayes	Decision Tree	SVM	Logistic Regression	MLP	
Relevants	78.61%	10.32%	1.11%	3.39%	2.02%	
Not Relevants	21.39%	89.68%	98.89%	96.61%	97.98%	

Task 2

Detecção de páginas com instâncias (classificação)

Resultados | Sem Feature Selection

Features = 12495

	Naïve Bayes	Decision Tree	SVM	Logistic Regression	MLP	
Accuracy	67.00%	85.50%	86.50%	89.00%	88.50%	
Precision	0.70	0.87	0.98	0.95	0.98	
Recall	0.79	0.84	0.75	0.82	0.79	
Training time	0.0896s	0.14s	0.377s	0.0615s	61.6s	

Resultados | Feature Selection (Frequência)

Features = 3000

	Naïve Bayes	Decision Tree	SVM	Logistic Regression	MLP
Accuracy	67.00%	83.00%	85.50%	88.00%	87.00%
Precision	0.71	0.88	0.98	0.95	0.98
Recall	0.79	0.76	0.73	0.80	0.76
Training time	0.016s	0.0406s	0.0841s	0.0156s	8.81s

Resultados | Feature Selection (Information Gain)

Features = 1000

	Naïve Bayes	Decision Tree	SVM	Logistic Regression	MLP
Accuracy	57.00%	77.00%	65.00%	80.00%	89.00%
Precision	0.54	0.83	0.79	0.77	0.89
Recall	0.93	0.72	0.53	0.85	0.89
Training time	0.00788s	0.0125s	0.0146s	0.0148s	4.03s


Feature Selection (Information Gain)


'specifications', 'click', 'accessories', 'days', 'details', 'box', 'note', 'favorite', 'program', 'single', 'snapdragon', 'shots', 'depending', 'products', 'security', 'smartphones', 'voice', 'blu', 'center', 'checking', 'country', 'nano', 'questions', 'smooth', 'close', 'copyright', 'instant', 'microsd', 'usage', 'year', 'ape', 'bank', 'beat', 'charged', 'claims', 'ends', 'gp', 'load', 'locking', 'number', 'pick', 'plan', 'processing', 'protect', 'reactivation', 'reviews', 'scenery', 'star', 'temperature', 'theft', 'avoid', 'coming', 'completely', 'connections', 'dex', 'groundbreaking', 'leading', 'meters', 'mov', 'ntsc', 'oct', 'old', 'platinum', 'revolutionary', 'rough', 'screenshots', 'sequence', 'shockproof', 'suggest', 'surround', 'typ', 'wallpapers', 'achieve', 'adapt', 'arrive', 'balance', 'breaks', 'bsi', 'calling', 'camcorder', 'cancelled', 'cash', 'come', 'confident', 'connectivity', 'correct', 'customizable', 'defects', 'durability', 'enable', 'ensures', 'equals', 'excludes', 'eyes', 'factory', 'functioning', 'gallery', 'gamut', 'globally', 'hardware', 'highly', 'holds', 'html', 'huawei', 'illumination', 'incorporates', 'languages', 'megapixels', 'middle', 'money', 'nearby', 'newsblu', 'nfc', 'otg', 'paired', 'paying', 'performed', 'phonesandroid', 'phonesfeature', 'possibilities', 'problem', 'processors', 'proximity', 'ghd', 'quickmemo', 'required', 'rotate', 'self', 'shopping', 'shortcut', 'speed', 'stop', 'stunningly', 'text', 'touchscreen'...

Task 3

Extração de instâncias

Extrator genérico





Resultados

	Samsung	LG	Apple	Sony	Xiaomi	Asus	Motorola	Blu	нтс	Banggood
Precision	on 1.00	1.00	0.80	1.00	1.00	1.00	1.00	1.00	1.00	1.00
Rec	all 1.00	1.00	0.50	0.75	1.00	0.62	0.87	0.87	0.87	0.87
F-Measu	re 1.00	1.00	0.61	0.86	1.00	0.77	0.93	0.93	0.93	0.93

Recuperação de informação

Coleta e busca de entidades estruturadas em um domínio