Recuperação de informação

Coleta e busca de entidades estruturadas em um domínio

Equipe & Tarefas

Isaac Douglas Webcrawler

Wellington Felix Classificação e extração

Domínio: Smartphones

Sites:

- 1. Banggood
- 2. Apple
- 3. Samsung
- 4. Asus
- 5. LG
- 6. Xiaomi
- 7. Motorola
- 8. Sony
- 9. Blu
- 10. HTC

















SONY htc

Task 1

Localização de páginas relevantes

Resultados Busca em largura

Files = 9.195

| | Naïve Bayes | Decision Tree | SVM | Logistic Regression | MLP | |
|---------------|-------------|---------------|--------|------------------------|--------|--|
| Relevants | 78.61% | 10.32% | 1.11% | 3.39% | 2.02% | |
| Not Relevants | 21.39% | 89.68% | 98.89% | 96.61% | 97.98% | |

Task 2

Detecção de páginas com instâncias (classificação)

Resultados | Sem Feature Selection

Features = 12495

| | Naïve Bayes | Decision Tree | SVM | Logistic Regression | MLP | |
|---------------|-------------|---------------|--------|------------------------|--------|--|
| Accuracy | 67.00% | 85.50% | 86.50% | 89.00% | 88.50% | |
| Precision | 0.70 | 0.87 | 0.98 | 0.95 | 0.98 | |
| Recall | 0.79 | 0.84 | 0.75 | 0.82 | 0.79 | |
| Training time | 0.0896s | 0.14s | 0.377s | 0.0615s | 61.6s | |

Resultados | Feature Selection (Frequência)

Features = 3000

| | Naïve Bayes | Decision Tree | SVM | Logistic Regression | MLP |
|---------------|-------------|---------------|---------|------------------------|--------|
| Accuracy | 67.00% | 83.00% | 85.50% | 88.00% | 87.00% |
| Precision | 0.71 | 0.88 | 0.98 | 0.95 | 0.98 |
| Recall | 0.79 | 0.76 | 0.73 | 0.80 | 0.76 |
| Training time | 0.016s | 0.0406s | 0.0841s | 0.0156s | 8.81s |

Resultados | Feature Selection (Information Gain)

Features = 1000

| | Naïve Bayes | Decision Tree | SVM | Logistic Regression | MLP |
|---------------|-------------|---------------|---------|------------------------|--------|
| Accuracy | 57.00% | 77.00% | 65.00% | 80.00% | 89.00% |
| Precision | 0.54 | 0.83 | 0.79 | 0.77 | 0.89 |
| Recall | 0.93 | 0.72 | 0.53 | 0.85 | 0.89 |
| Training time | 0.00788s | 0.0125s | 0.0146s | 0.0148s | 4.03s |


Feature Selection (Information Gain)


'camera', 'mp', 'gb', 'sim', 'lte', 'ram', 'mobile', 'battery', 'gsm', 'fps', 'memory', 'photos', 'snapdragon', 'microsd', 'mah', 'fingerprint', 'capture', 'octa', 'dual', 'display', 'phones', 'selfie', 'video', 'phone', 'gps', 'rom', 'smartphone', 'fdd', 'qualcomm', 'sensor', 'recording', 'rear', 'resolution', 'core', 'nfc', 'selfies', 'umts', 'main', 'ghz', 'carrier', 'glass', 'com', 'light', 'card', 'support', 'hspa', 'network', 'face', 'slow', 'aperture', 'aac', 'pdaf', 'buy', 'flash', 'nano', 'unlocked', 'cdma', 'processor', 'glonass', 'gorilla', 'technology', 'bluetooth', 'super', 'motion', 'focus', 'specifications', 'device', 'image', 'dimensions', 'fi', 'proximity', 'flac', 'wav', 'mode', 'usb', 'supported', 'ppi', 'wi', 'storage', 'sharp', 'account', 'autofocus', 'hdr', 'panorama', 'charge', 'available', 'stabilization', 'new', 'weight', 'talk', 'detection', 'internal', 'learn', 'nougat', 'bands', 'wireless', 'cat', 'plus', 'hd', 'android', 'free', 'warranty', 'videos', 'cameras', 'corning', 'mkv', 'tv', 'connectivity', 'images', 'time', 'pictures', 'power', 'high', 'samsung', 'ambient', 'coverage', 'performance', 'inch', 'gprs', 'liquid', 'ois', 'water', 'screen', 'mi', 'accessories', 'lens', 'pixel', 'networks', 'capacity', 'subject', 'reviews', 'program', 'auto', 'shipping', 'wide', 'vary', 'led', 'google', 'gp', 'wet', 'hid', 'hotspot', 'mhz', 'damage', 'yes', 'limited', 'pay', 'accelerometer', 'service', 'htc', 'format', 'hours', 'apple', 'care', 'financing', 'change', 'intel', 'quad', 'shots', 'apps', 'ogg', 'galaxy', 'terms', 'addition', 'micro', 'continue', 'features', 'help', 'photo', 'lg', 'calling', 'days', 'standby', 'cell', 'exposure', 'cover', 'pro', 'great', 'cpu', 'mm', 'type', 'moto', 'charging', 'mac', 'adaptive', 'conditions', 'adreno', 'webm', 'tdd', 'edge', 'latest', 'software', 'product', 'user', 'energy', 'required', 'payments', 'iphone', 'depends', 'unlock', 'angle', 'ac', 'replacement', 'formats', 'apply', 'connect', 'mbps', 'timer', 'pixels', 'credit', 'purchase', 'volte', 'picture', 'zoom', 'convenience', 'offer', 'actual', 'close', 'life', 'note', 'fast', 'provider', 'compass', ...

Task 3

Extração de instâncias

Extrator genérico





Resultados

| | Samsung | LG | Apple | Sony | Xiaomi | Asus | Motorola | Blu | нтс | Banggood |
|-----------|----------|------|-------|------|--------|------|----------|------|------|----------|
| Precision | on 1.00 | 1.00 | 0.80 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 |
| Rec | all 1.00 | 1.00 | 0.50 | 0.75 | 1.00 | 0.62 | 0.87 | 0.87 | 0.87 | 0.87 |
| F-Measu | re 1.00 | 1.00 | 0.61 | 0.86 | 1.00 | 0.77 | 0.93 | 0.93 | 0.93 | 0.93 |

Recuperação de informação

Coleta e busca de entidades estruturadas em um domínio